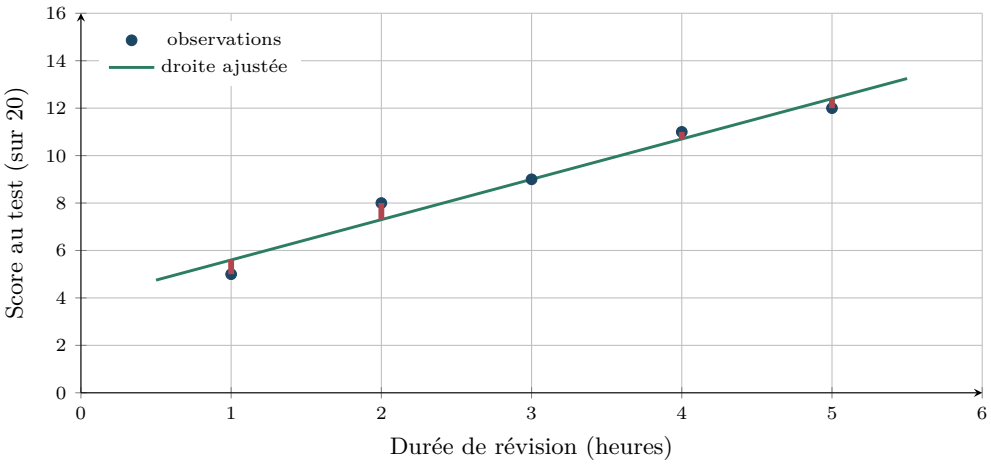
La droite des moindres carrés

Idée essentielle

Pour un nuage de points $(x_i ; y_i)$, on cherche une droite $y = ax + b$ qui représente au mieux sa tendance. Pour chaque point, l'écart vertical à la droite est le **résidu**

$$e_i = y_i - (ax_i + b).$$

La **droite des moindres carrés** rend minimale la **somme des carrés des résidus** : $E = \sum e_i^2$. Le carré empêche les écarts positifs et négatifs de s'annuler et donne plus de poids aux grands écarts.



Les segments rouges représentent les **résidus**. Le **point moyen** est $G(3;9)$: la droite ajustée passe par G.

Méthode des moindres carrés

On note $\bar{x}$ et $\bar{y}$ les **moyennes** des valeurs. On calcule

$$S_{xx} = \sum (x_i - \bar{x})^2, \qquad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}).$$

Si les x_i ne sont pas tous égaux, les coefficients de la droite des moindres carrés sont

$$\boxed{a = \frac{S_{xy}}{S_{xx}}}, \qquad \boxed{b = \bar{y} - a\bar{x}}.$$

La droite s'écrit alors $y = ax + b$ et passe toujours par le **point moyen** $G(\bar{x};\bar{y})$.

Approfondissement – Pourquoi ces formules ?

Pour une pente a fixée, la somme des carrés est minimale lorsque la droite passe par le point moyen, donc $b = \bar{y} - a\bar{x}$. On note alors $E(a)$ la somme des carrés des résidus de cette droite. En posant $S_{yy} = \sum (y_i - \bar{y})^2$, on peut écrire

$$E(a) = S_{yy} - 2aS_{xy} + a^2 S_{xx} = S_{xx}\left(a - \frac{S_{xy}}{S_{xx}}\right)^2 + S_{yy} - \frac{S_{xy}^2}{S_{xx}}.$$

Le dernier terme est constant et le carré est minimal pour $a = S_{xy}/S_{xx}$: c'est la pente recherchée.

Exemple rapide

Pour les données du graphique, $\bar{x} = 3$, $\bar{y} = 9$, $S_{xx} = 10$ et $S_{xy} = 17$. Ainsi,

$$a = \frac{17}{10} = 1{,}7, \qquad b = 9 - 1{,}7 \times 3 = 3{,}9.$$

La droite ajustée est donc $y = 1{,}7x + 3{,}9$; elle passe par le point moyen $G(3;9)$. Les segments rouges montrent les écarts verticaux entre les observations et cette droite.

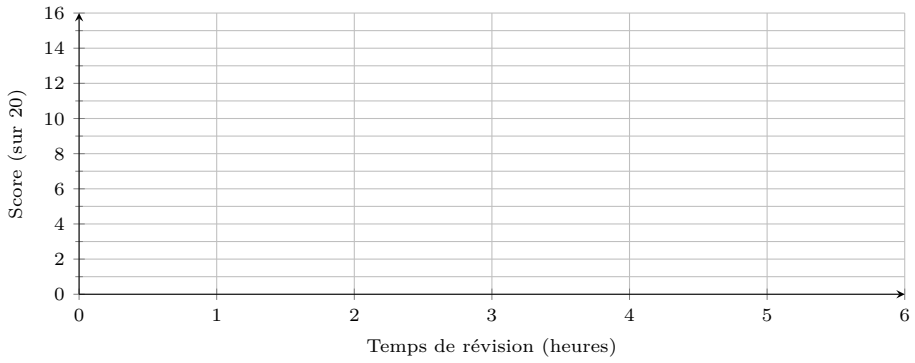
Exercice guidé

Déterminer à la main une droite des moindres carrés

Un élève compare son temps de révision et son score à cinq tests. On note x le temps de révision, en heures, et y le score obtenu, sur 20.

Test i	1	2	3	4	5
Temps x_i (h)	1	2	3	4	5
Score y_i (/20)	5	8	9	11	12

1. Placer les cinq points du tableau dans le repère ci-dessous.



2. Calculer $\bar{x}$ et $\bar{y}$, puis donner les coordonnées du point moyen G.
3. Compléter le tableau. Les deux dernières colonnes servent à calculer S_{xy} et S_{xx}.

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	1	5				
2	2	8				
3	3	9				
4	4	11				
5	5	12				
				Sommes		

4. Calculer S_{xy} et S_{xx}, puis en déduire la pente a. Calculer ensuite $b = \bar{y} - a\bar{x}$ et écrire l'équation de la droite, puis la tracer dans le repère ci-dessus.

5. Avec cette droite, compléter les valeurs prédites $\widehat{y_i}$, les résidus $e_i = y_i - \widehat{y_i}$ et leurs carrés.

x_i	1	2	3	4	5
y_i observé	5	8	9	11	12
$\widehat{y_i}$ prédit					
Résidu e_i					
e_i^2					

6. Additionner les carrés des résidus. À l'aide de la formule de la page précédente, comparer cette somme à celle de la droite $y = 1{,}5x + 4{,}5$, qui passe elle aussi par le point moyen.

7. Selon le modèle obtenu, estimer le score pour 4,5 heures de révision. Cette estimation est-elle une **interpolation** ou une **extrapolation** ?

Corrigé

1. Moyennes et point moyen.

$$\bar{x} = \frac{1+2+3+4+5}{5} = 3, \qquad \bar{y} = \frac{5+8+9+11+12}{5} = 9.$$

Ainsi, $G(3;9)$.

2. Tableau de calcul. On soustrait les moyennes à chaque valeur, puis on calcule les produits et les carrés demandés.

i	x_i	y_i	$x_i - 3$	$y_i - 9$	$(x_i-3)(y_i-9)$	$(x_i-3)^2$
1	1	5	-2	-4	8	4
2	2	8	-1	-1	1	1
3	3	9	0	0	0	0
4	4	11	1	2	2	1
5	5	12	2	3	6	4
				Sommes	$S_{xy} = 17$	$S_{xx} = 10$

3. Coefficients de la droite.

$$a = \frac{S_{xy}}{S_{xx}} = \frac{17}{10} = 1{,}7, \qquad b = \bar{y} - a\bar{x} = 9 - 1{,}7 \times 3 = 3{,}9.$$

La droite des moindres carrés est donc

$$\boxed{y = 1{,}7x + 3{,}9}.$$

Elle passe bien par $G(3;9)$ puisque $1{,}7 \times 3 + 3{,}9 = 9$.

4. Résidus et somme des carrés.

x_i	1	2	3	4	5
y_i observé	5	8	9	11	12
$\widehat{y_i} = 1{,}7x_i + 3{,}9$	5,6	7,3	9	10,7	12,4
$e_i = y_i - \widehat{y_i}$	$-0{,}6$	0,7	0	0,3	$-0{,}4$
e_i^2	0,36	0,49	0	0,09	0,16

La somme des carrés des résidus vaut

$$E = 0{,}36 + 0{,}49 + 0 + 0{,}09 + 0{,}16 = 1{,}10.$$

Pour $y = 1{,}5x + 4{,}5$, les valeurs prédites sont 6 ; 7,5 ; 9 ; 10,5 ; 12. Les résidus sont -1 ; 0,5 ; 0 ; 0,5 ; 0, donc la somme de leurs carrés vaut 1,5. Elle est supérieure à 1,10 : la droite des moindres carrés minimise bien cette somme.

5. Estimation. Pour $x = 4{,}5$ heures,

$$y = 1{,}7 \times 4{,}5 + 3{,}9 = 11{,}55.$$

Le modèle estime donc un score d'environ 11,6/20 (ou 12/20 à l'unité). Comme 4,5 est compris entre les temps observés 1 et 5, il s'agit d'une **interpolation**.

À retenir. La **pente** mesure la variation moyenne estimée de y lorsque x augmente d'une unité. Ici, le modèle prévoit environ 1,7 point de score supplémentaire par heure de révision. Une droite reste un modèle : évitez de l'utiliser trop loin de la plage observée.